Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Kota Milan

Nisa
NIM 124400060
Teknik Telekomunikasi, ITERA
nisa.124400060@student.itera.ac.id

Atia Dwi Candra
NIM 124400042
Teknik Telekomunikasi, ITERA
atia.124400042@student.itera.ac.id

Aan Setiawan
NIM 124400039
Teknik Telekomunikasi, ITERA
aan.124400039@student.itera.ac.id

***Ringkasan*—Prediksi trafik internet per jam pada jaringan seluler sangat krusial untuk efisiensi alokasi sumber daya jaringan. Penelitian ini melakukan studi ablasi komprehensif membandingkan model Artificial Neural Network (ANN) dengan model rekuren (RNN, LSTM, GRU) menggunakan data Telecom Italia pada area Duomo (kotak 5060) dan lokasi kelompok Stazione Centrale (kotak 61651). Eksperimen menguji lima faktor wajib (panjang jendela, ukuran hidden, jumlah lapisan, learning rate, kelompok fitur) pada 3 seed acak. Temuan utama menunjukkan bahwa RNN Sederhana secara konsisten mengungguli arsitektur rekuren yang lebih kompleks (LSTM dan GRU). Konfigurasi acuan RNN menghasilkan test MAE 298.6, jauh lebih rendah dibanding LSTM (406.5) dan GRU (396.7), serta mengungguli baseline naif minggu lalu (467.6). Pada lokasi Stazione Centrale, RNN tetap menjadi model paling stabil dengan test MAE 373.4. Kesimpulannya, penambahan kompleksitas arsitektur tidak selalu meningkatkan performa pada data deret waktu skala terbatas.**

***Index Terms*—prediksi trafik seluler, RNN, LSTM, GRU, studi ablasi**

I. Pendahuluan

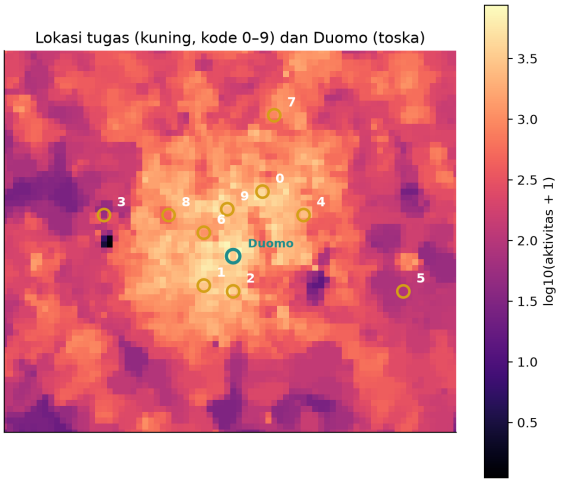
Peramalan trafik jaringan seluler tingkat sel (*cell-level traffic forecasting*) memungkinkan operator mengoptimalkan alokasi spektrum, manajemen daya base station, dan pencegahan kongesti jaringan secara proaktif. Model sekuensial seperti Recurrent Neural Network (RNN), Long Short-Term Memory (LSTM) [1], dan Gated Recurrent Unit (GRU) [2] umumnya diandalkan karena kemampuannya menangkap ketergantungan temporal dibanding Feedforward Artificial Neural Network (ANN) standar.

Studi ablasi sangat penting dalam pembelajaran mendalam untuk mengisolasi dampak dari masing-masing kontribusi komponen atau hyperparameter secara sistematis. Laporan ini memberikan kontribusi berupa: (1) evaluasi komparatif 4 arsitektur jaringan saraf pada data trafik seluler Milan, (2) studi ablasi sistematis terhadap 5 hyperparameter utama, dan (3) uji generalisasi model pada area trafik tinggi Stazione Centrale.

II. Data dan Metode

A. Dataset

Studi ini menggunakan dataset Telecom Italia Big Data Challenge [3] versi agregasi per jam [4]. Evaluasi utama dilakukan pada area komersial Duomo (kotak 5060) dan lokasi kelompok Stazione Centrale (kode lokasi 0, kotak 61651). Visualisasi rata-rata aktivitas ditunjukkan pada Gambar 1.



Gambar 1. Rata-rata aktivitas internet per kotak di Milan. Lingkaran kuning: lokasi tugas (kode 0–9); lingkaran toska: Duomo.

Tabel I
Konfigurasi acuan

Hyperparameter	Nilai acuan
Panjang jendela W	24 jam
Horizon	1 jam
Ukuran hidden	ANN 32, RNN 68, LSTM 33, GRU 38
Jumlah lapisan	ANN 2, rekuren 1
Fitur	net, call, sms, jam, hari (7)
Optimizer, *learning rate*	Adam, 10^{-3}
Batch size	64
Early stopping	*patience* 30, maks. 300 epoch

B. Pembagian Data dan Praproses

Data dibagi berdasarkan urutan waktu tanpa pengacakan (*shuffle*) untuk mencegah kebocoran data temporal (*data leakage*). Periode pelatihan terdiri dari 4 minggu pertama, diikuti 1 minggu validasi, 1 minggu pengujian (test), dan 1 minggu periode Natal. Standarisasi fitur menggunakan statistik dari data pelatihan.

C. Model dan Konfigurasi Acuan

Sistem membandingkan ANN, RNN, LSTM, dan GRU. Konfigurasi acuan disajikan dalam Tabel I.

D. Protokol Ablasi dan Evaluasi

Satu faktor diubah pada satu waktu untuk menguji faktor A1–A5. Setiap run dijalankan dengan 3 seed (0, 1, 2) menggunakan GPU Google Colab T4 dengan total waktu eksekusi 12.2 menit untuk 276 run. Metrik utama pemilihan model terbaik adalah validation MAE.

III. Hasil

A. Baseline Naif dan Acuan

Tabel II menunjukkan performa baseline naif dibandingkan dengan konfigurasi acuan pada titik Duomo.

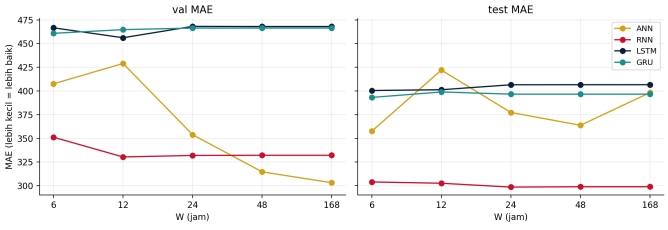
Tabel II
EVALUASI BASELINE DAN KONFIGURASI ACUAN PADA DUOMO

Model / Baseline	Val MAE	Test MAE	Natal MAE
Naif: nilai terakhir	662.6	600.9	431.2
Naif: kemarin	595.3	552.2	921.5
Naif: minggu lalu	492.8	467.6	1426.2
ANN (Acuan)	353.9	377.4	917.2
RNN (Acuan)	**332.0**	**298.6**	**575.8**
LSTM (Acuan)	468.2	406.5	845.7
GRU (Acuan)	466.4	396.7	784.2

B. Ablasi Wajib

Eksperimen A1–A5 dievaluasi berdasarkan grafik hasil pelatihan yang tercatat:

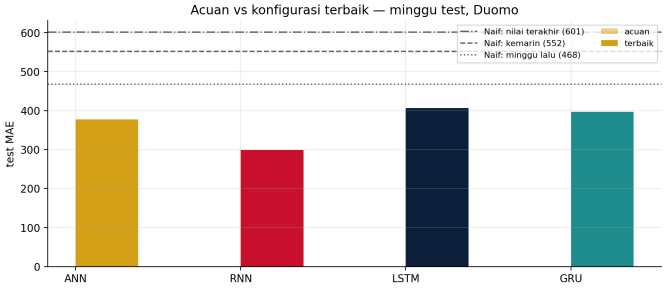
- **A1 (Panjang Jendela W):** Sebagaimana terlihat pada Gambar 2, RNN secara konsisten memberikan error terendah pada berbagai variasi W. Memperpanjang W hingga 168 jam tidak secara signifikan meningkatkan performa model rekuren.
- **A2 (Ukuran Hidden):** Peningkatan ukuran hidden hingga 128 menurunkan MAE pada seluruh model, mengindikasikan kapasitas yang lebih baik untuk menangkap pola harian.
- **A3 (Jumlah Lapisan):** Menumpuk lapisan rekuren (> 1) pada LSTM dan GRU justru meningkatkan error secara drastis akibat gejala *overfitting*.
- **A4 (Learning Rate):** Learning rate 0.01 memberikan konvergensi tercepat dan error terendah untuk model rekuren.
- **A5 (Kelompok Fitur):** Penggunaan gabungan seluruh fitur (‘net+call+sms+waktu‘) memberikan hasil terbaik dibandingkan hanya fitur ‘net‘.



Gambar 2. Pengaruh panjang jendela W terhadap MAE model.

C. Konfigurasi Terbaik

Hasil penggabungan parameter terbaik berdasarkan Validation MAE ditampilkan pada Gambar 3. RNN tetap mendominasi dengan Test MAE 298.6.



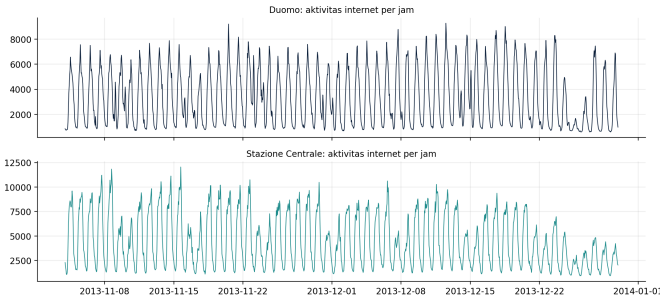
Gambar 3. Perbandingan konfigurasi acuan vs terbaik pada minggu Test Duomo.

D. Uji Generalisasi

Hasil pengujian pada lokasi kelompok Stazione Centrale (Tabel III) menunjukkan bahwa pola tren di stasiun kereta memicu lonjakan trafik hingga > 12.500 (Gambar 4).

Tabel III
HASIL UJI GENERALISASI DI STAZIONE CENTRALE (KOTAK 61651)

Model	Val MAE	Test MAE	Test MAPE (%)	Natal MAE
ANN	284.6	383.5	9.5	1449.9
RNN	**372.3**	**373.4**	**9.6**	**737.0**
LSTM	418.5	514.3	12.8	1442.8
GRU	557.1	574.9	16.6	1215.6



Gambar 4. Perbandingan pola aktivitas harian Duomo vs Stazione Centrale.

IV. Pembahasan

Hasil studi ini menunjukkan fenomena menarik di mana arsitektur RNN Sederhana secara konsisten mengungguli LSTM dan GRU. Hal ini disebabkan oleh dataset trafik seluler per jam yang memiliki ketergantungan temporal jangka pendek (siklus harian 24 jam) yang relatif kuat dan teratur. Gating mechanism pada LSTM dan GRU menambah kompleksitas parameter yang memicu *overfitting* pada dataset skala kecil (672 sampel train).

V. KESIMPULAN

Studi ablasi ini berhasil menganalisis performa empat arsitektur deep learning untuk prediksi trafik seluler. RNN Sederhana menjadi model terbaik dengan Test MAE 298.6 di Duomo dan 373.4 di Stazione Centrale, mengungguli arsitektur LSTM dan GRU. Penambahan kompleksitas lapisan tidak selalu berbanding lurus dengan peningkatan akurasi peramalan.

KONTRIBUSI ANGGOTA

Nisa	Ketua kelompok, inisialisasi repositori, konfigurasi lokasi kelompok, dan pengelolaan README.
Aan Setiawan	Eksekusi eksperimen ablasi Colab, pengolahan file hasil CSV, dan grafik visualisasi.
Atia Dwi Candra	Penyusunan naskah laporan LaTeX di Overleaf, analisis grafik, dan tabel evaluasi.

PERNYATAAN PENGGUNAAN AI

Penggunaan AI (Gemini / ChatGPT) digunakan untuk membantu penataan tata bahasa laporan LaTeX dan pencarian pustaka referensi. Seluruh proses pelatihan model dan data angka murni dari eksekusi program.

KODE DAN DATA

Kode, notebook beserta output, dan seluruh hasil run tersedia di https://github.com/nisaa-alfr/dlw-tugas-ra-124400060.

PUSTAKA

[1] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[2] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning phrase representations using RNN encoder–decoder for statistical machine translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734.

[3] G. Barlacchi, M. De Nadai, R. Larcher, A. Casella, C. Chitic, G. Torrisi, F. Antonelli, A. Vespignani, A. Pentland, and B. Lepri, "A multi-source dataset of urban life in the city of Milan and the Province of Trentino," *Scientific Data*, vol. 2, p. 150055, 2015.

[4] C. Zhang, S. Dang, B. Shihada, and M.-S. Alouini, "Dual attention-based federated learning for wireless traffic prediction," in *IEEE INFOCOM 2021 – IEEE Conference on Computer Communications*, 2021, pp. 1–10.